

O que a porta espectral realmente contribui? Decomposição da vantagem preditiva de mecanismos de *gating* frente a seleção de variáveis clássica em quimiometria

Rodrigo Fernandes

Orientador: Prof. Dr. Clarimar José Coelho

Pontifícia Universidade Católica de Goiás

12 de agosto de 2026

Resumo

Mecanismos de *gating* espectral guiados por conhecimento prévio têm sido propostos como alternativa interpretável ao PLS em espectroscopia vibracional, e reportam ganhos preditivos consistentes sobre a linha de base linear. Esses ganhos, porém, jamais foram decompostos: um modelo desse tipo combina simultaneamente regressor não linear, ponderação espectral e seleção implícita de variáveis, e nenhuma dessas contribuições foi isolada. Além disso, a comparação é habitualmente feita contra o PLS sobre o espectro completo, e não contra os métodos de seleção de variáveis que constituem o estado da prática em quimiometria — iPLS, CARS e GA-PLS. Esta proposta apresenta um estudo de atribuição com delineamento fatorial cruzando *regressor* (linear, não linear) e *representação espectral* (espectro completo, ponderação fixa por prior, porta aprendida, bandas selecionadas por métodos clássicos), avaliado em quatro conjuntos públicos de duas modalidades (NIR e Raman). A vantagem observada é decomposta em termos aditivos com significado individual, e as afirmações de ausência de diferença são testadas por equivalência estatística (TOST), não por mera não rejeição da hipótese nula. A hipótese de trabalho é que a maior parte do ganho seja atribuível ao regressor não linear, e que a contribuição própria do *gating* resida na *reprodutibilidade* do conjunto de bandas selecionadas — ponto em que os métodos clássicos de seleção são reconhecidamente instáveis.

Sumário

1	Introdução e Justificativa	3
1.1	Contexto	3
1.2	As três lacunas	3
1.3	A pergunta do trabalho	3
1.4	Por que isso é publicável independentemente do desfecho	3
2	Objetivo Geral	4
3	Objetivos Específicos	4
4	Delineamento Experimental	4
4.1	A grade de atribuição	4
4.2	A decomposição	5
4.3	Conjuntos de dados	5
4.4	Protocolo de avaliação comum	5

4.5	Métricas	6
4.6	Protocolo estatístico	6
5	Hipóteses Pré-Registradas	6
6	Plano de Trabalho	7
6.1	1º Semestre	7
6.2	2º Semestre	7
6.3	Cronograma	7
7	Entregáveis	7
8	Riscos e Mitigações	8
9	Delimitação frente ao Programa de Pesquisa	8
10	Autoria	8

1 Introdução e Justificativa

1.1 Contexto

A seleção de variáveis é problema central em quimiometria. Em espectroscopia vibracional, o regime $n \ll p$ e a forte colinearidade entre bandas tornam proveitoso restringir o modelo a regiões espectrais informativas, e a literatura consolidou para isso um conjunto de métodos: iPLS, baseado em intervalos; CARS, por reamostragem competitiva adaptativa; GA-PLS, por algoritmos genéticos; e limiarização de escores VIP.

Mais recentemente, arquiteturas profundas passaram a implementar seleção de variáveis de forma diferenciável, por meio de portas (*gates*) que aprendem um peso multiplicativo por banda, frequentemente inicializadas a partir de conhecimento espectroscópico prévio. Trabalhos desse tipo reportam ganho preditivo sobre o PLS e apresentam o *gate* aprendido como mapa de relevância interpretável.

1.2 As três lacunas

Lacuna 1 — o ganho nunca foi decomposto. Um modelo com porta espectral difere do PLS em pelo menos três dimensões simultâneas: possui regressor não linear, aplica ponderação espectral e realiza seleção implícita de variáveis. Reportar que ele supera o PLS não informa *qual* dessas dimensões produziu o ganho. É inteiramente possível que a contribuição venha do regressor não linear e que a porta seja preditivamente inerte — hipótese nunca testada porque o controle óbvio, um regressor equivalente *sem* porta, não costuma constar dos experimentos.

Lacuna 2 — o competidor escolhido é fraco. A comparação padrão é contra PLS sobre o espectro completo. Esse não é o estado da prática: um quimiometrista que enfrentasse o mesmo problema aplicaria iPLS ou CARS antes de ajustar o modelo final. Comparar um mecanismo de seleção diferenciável contra um modelo *sem* seleção é comparação enviesada por construção. A pergunta pertinente é se a porta supera a seleção clássica, e essa pergunta permanece aberta.

Lacuna 3 — afirmações de equivalência sem teste de equivalência. Resultados recentes indicam que o prior informativo não produz ganho preditivo detectável ($p \approx 0,77$ em replicação com sementes independentes). Não rejeitar a hipótese nula, contudo, não é evidência de ausência de efeito — sobretudo com o tamanho amostral típico desses experimentos. Afirmar equivalência exige teste de equivalência, com margem declarada previamente.

1.3 A pergunta do trabalho

Dada a vantagem preditiva observada de um mecanismo de *gating* espectral sobre a linha de base linear, quanto dela é atribuível ao regressor não linear, quanto à ponderação espectral, quanto ao aprendizado da porta e quanto ao conhecimento prévio injetado — e o que resta quando o competidor é a seleção de variáveis clássica?

1.4 Por que isso é publicável independentemente do desfecho

O resultado esperado é parcialmente deflacionário: é provável que o regressor não linear responda pela maior parte do ganho. Isso não esvazia o trabalho, por dois motivos.

Primeiro, decomposições de atribuição rigorosas são contribuição reconhecida em aprendizado de máquina aplicado, precisamente porque a literatura tende a acumular ganhos não decompostos. Um estudo que quantifica cada termo, em duas modalidades e contra competidores fortes, é referência útil mesmo — ou especialmente — quando desinfla resultados anteriores.

Segundo, há um desfecho positivo plausível e específico. Métodos clássicos de seleção como CARS e GA-PLS são reconhecidamente instáveis: execuções distintas sobre os mesmos dados selecionam conjuntos de bandas substancialmente diferentes, o que compromete a interpretação química. Se a porta diferenciável apresentar reprodutibilidade muito superior *com desempenho estatisticamente equivalente*, então sua contribuição está caracterizada com precisão — não como ganho de acurácia, mas como estabilidade da seleção. Essa é uma afirmação forte, verificável e útil para a prática.

2 Objetivo Geral

Decompor a vantagem preditiva de mecanismos de *gating* espectral em termos atribuíveis ao regressor, à ponderação, ao aprendizado da porta e ao prior, e compará-los a métodos consolidados de seleção de variáveis em quimiometria, avaliando conjuntamente acurácia e reprodutibilidade da seleção.

3 Objetivos Específicos

- a) Implementar, sob protocolo de avaliação único, os braços clássicos: PLS sobre espectro completo, iPLS, CARS, GA-PLS e limiarização de VIP.
- b) Implementar os braços de regressão não linear com e sem porta, mantendo regressor idêntico entre eles.
- c) Executar o delineamento fatorial *regressor* $\times$ *representação espectral* nos quatro conjuntos de dados.
- d) Decompor a vantagem observada em termos aditivos com interpretação individual definida previamente.
- e) Testar equivalência estatística (TOST) para todos os termos declarados como nulos, com margem fixada no protocolo.
- f) Quantificar a reprodutibilidade do conjunto de bandas selecionadas por cada método, entre sementes e entre partições.
- g) Avaliar a concordância química entre as bandas selecionadas por cada método e as janelas de atribuição espectroscópica conhecida.
- h) Entregar protocolo pré-registrado, código reprodutível e um *benchmark* público reutilizável.

4 Delineamento Experimental

4.1 A grade de atribuição

O delineamento cruza duas dimensões. A célula vazia é estrutural: porta aprendida por gradiente não se aplica a um regressor linear ajustado por mínimos quadrados parciais.

Representação espectral	Regressor linear (PLS)	Regressor não linear (MLP)
Espectro completo	A1	B1
Ponderação fixa pelo prior	A2	B2
Porta aprendida, init. uniforme	—	B3
Porta aprendida, init. prior	—	B4
Bandas selecionadas (iPLS)	A3	B5
Bandas selecionadas (CARS)	A4	B6
Bandas selecionadas (GA-PLS)	A5	B7
Bandas selecionadas (VIP)	A6	B8

O braço B4 corresponde ao modelo completo tal como publicado; A1 corresponde à linha de base habitualmente reportada. Todo o restante da grade é controle que a literatura não executa.

4.2 A decomposição

Cada termo é uma diferença entre dois braços que se distinguem por exatamente uma característica, e recebe interpretação declarada antes da execução:

Termo	Contraste	Interpretação
$\Delta_{\text{não-lin}}$	B1 – A1	contribuição do regressor não linear
$\Delta_{\text{ponderação}}$	B2 – B1	contribuição da ponderação fixa pelo prior
$\Delta_{\text{aprendizado}}$	B4 – B2	contribuição de tornar a porta treinável
Δ_{prior}	B4 – B3	contribuição do conhecimento prévio injetado
$\Delta_{\text{vs-clássico}}$	B4 – $\max_i A_i$	vantagem sobre a melhor seleção clássica

A soma dos quatro primeiros termos reconstitui, por construção, a diferença B4 – A1 — exatamente o ganho reportado na literatura. O trabalho consiste em mostrar como esse total se reparte.

4.3 Conjuntos de dados

Conjunto	Modalidade	Regime	Alvo
Gasoline	NIR	n muito pequeno	octanagem
Tecator	NIR	n pequeno	teor de gordura
Mango DMC v3	NIR	n grande	matéria seca
Bioprocesso	Raman	n grande	concentração de glicose

A cobertura de duas modalidades e de regimes amostrais contrastantes é o que permite afirmar que a decomposição não é particular a um domínio. É plausível — e deve ser testado — que os termos se reordenem entre regimes: a ponderação por prior tende a valer mais quando n é pequeno.

4.4 Protocolo de avaliação comum

Todos os braços compartilham partições, sementes, pré-processamento e orçamento de ajuste de hiperparâmetros. Métodos clássicos de seleção recebem tratamento justo: número de intervalos em iPLS, iterações de CARS e população de GA-PLS ajustados por validação cruzada interna, na mesma faixa de esforço concedida ao modelo neural. Um *benchmark* em que o competidor não recebe ajuste é inválido, e será rejeitado em revisão.

4.5 Métricas

Desempenho. R^2 , RMSE e RMSEP em teste isolado, com dez sementes independentes por célula.

Reprodutibilidade da seleção. Índice de Jaccard entre conjuntos de bandas selecionadas, calculado entre sementes e entre partições. Para os métodos com porta contínua, o conjunto é definido pelas k bandas de maior peso, com k fixado no protocolo e igual ao número médio de bandas retidas pelos métodos clássicos — garantindo comparação de mesma cardinalidade.

Plausibilidade química. Sobreposição entre bandas selecionadas e janelas de atribuição espectroscópica documentada, reportada por método.

Custo. Tempo de ajuste por braço, incluindo busca de hiperparâmetros. É informação prática relevante e raramente reportada.

4.6 Protocolo estatístico

Comparação global entre braços por teste de Friedman sobre os conjuntos, com pós-teste pareado e correção para múltiplas comparações. Toda afirmação de ausência de diferença é submetida a teste de equivalência TOST, com margem de equivalência em unidades de R^2 declarada no protocolo antes da execução. Sementes propagadas explicitamente, com verificação automatizada de que réplicas não são idênticas.

5 Hipóteses Pré-Registradas

- H1.** $\Delta_{\text{não-lin}}$ é o termo dominante da decomposição, respondendo pela maior parte do ganho B4 – A1.
- H2.** $\Delta_{\text{ponderação}}$ é estatisticamente equivalente a zero pela margem declarada.
- H3.** Δ_{prior} é estatisticamente equivalente a zero, confirmando por teste de equivalência o resultado anteriormente obtido por não rejeição.
- H4.** $\Delta_{\text{vs-clássico}}$ é estatisticamente equivalente a zero: a porta diferenciável *não* supera a melhor seleção clássica em acurácia.
- H5.** A reprodutibilidade da seleção (Jaccard entre sementes) da porta diferenciável é substancialmente superior à de CARS e GA-PLS, com diferença detectável e de magnitude prática relevante.
- H6.** A vantagem em reprodutibilidade aumenta quando a porta é inicializada com prior informativo (B4 *versus* B3), replicando em contexto comparativo o achado já obtido isoladamente.
- H7.** A ordenação dos termos da decomposição depende do regime amostral: $\Delta_{\text{ponderação}}$ e Δ_{prior} são maiores em n pequeno.

H1–H4 são enunciadas na direção deflacionária deliberadamente. São os desfechos considerados mais prováveis, e declará-los antecipadamente impede que resultados nulos sejam reinterpretados após o fato. H5 é a hipótese positiva do trabalho e concentra sua contribuição potencial.

6 Plano de Trabalho

6.1 1º Semestre

1. Revisão dirigida: seleção de variáveis em PLS (iPLS, CARS, GA-PLS, VIP), testes de equivalência e comparação de múltiplos algoritmos — Mês 1.
2. Ingestão dos quatro conjuntos sob interface comum; protocolo de partição e pré-processamento — Mês 2.
3. Implementação e validação dos braços clássicos contra resultados publicados na literatura para os mesmos conjuntos — Mês 3.
4. Implementação dos braços neurais com regressor idêntico e verificação contra o modelo de referência do grupo — Mês 4.
5. Protocolo pré-registrado congelado, com margem de equivalência e k definidos; piloto em Tecator — Mês 5.

6.2 2º Semestre

1. Execução da grade completa nos quatro conjuntos — Mês 1.
2. Decomposição, testes de equivalência e análise de reprodutibilidade — Mês 2.
3. Análise de plausibilidade química e de custo; figuras — Mês 3.
4. Manuscrito, monografia e defesa — Mês 4.

6.3 Cronograma

Etapas	1º Sem.	2º Sem.
Revisão dirigida	Mês 1	—
Ingestão e protocolo de avaliação	Mês 2	—
Braços clássicos e validação	Mês 3	—
Braços neurais e verificação	Mês 4	—
Protocolo congelado e piloto	Mês 5	—
Grade completa	—	Mês 1
Decomposição e equivalência	—	Mês 2
Reprodutibilidade, química e custo	—	Mês 3
Manuscrito, monografia e defesa	—	Mês 4

7 Entregáveis

1. *Benchmark* público reutilizável: quatro conjuntos, doze braços, protocolo de avaliação único, código versionado.
2. Protocolo pré-registrado datado, com margem de equivalência declarada.
3. Tabela de decomposição por conjunto e por regime amostral.
4. Manuscrito submetido a periódico com revisão por pares.
5. Monografia de TCC e apresentação de defesa.

8 Riscos e Mitigações

- **Resultado desfavorável ao próprio programa de pesquisa:** é o desfecho esperado em H1–H4. Mitigação — o enquadramento do trabalho é de atribuição, não de defesa; a contribuição prometida é a decomposição e o *benchmark*, e H5 concentra o desfecho positivo. Publicar a análise é preferível a recebê-la de um revisor.
- **Implementação injusta dos competidores clássicos:** risco central de credibilidade. Mitigação — usar implementações estabelecidas quando disponíveis, validar contra resultados publicados para os mesmos conjuntos antes de qualquer comparação, e conceder orçamento de ajuste equivalente. Nenhuma comparação é reportada antes dessa validação.
- **Instabilidade de CARS e GA-PLS dificultando a comparação:** a instabilidade é justamente o objeto de H5, mas pode gerar dispersão elevada. Mitigação — número maior de réplicas nesses braços e relato de dispersão completa, não apenas de médias.
- **Cardinalidade não pareada entre métodos:** comparar Jaccard entre seleções de tamanhos distintos é enganoso. Mitigação — k fixado e igual entre métodos, com análise de sensibilidade a k .
- **Margem de equivalência escolhida após ver os dados:** invalidaria H2–H4. Mitigação — margem fixada no protocolo congelado, com justificativa em termos de relevância prática em R^2 .
- **Volume computacional:** doze braços, quatro conjuntos, dez sementes, com busca de hiperparâmetros. Mitigação — modelos leves, GPU NVIDIA, execução retomável e grade reduzível a três conjuntos sem perda das conclusões principais.

9 Delimitação frente ao Programa de Pesquisa

Três frentes tratam do mesmo mecanismo por ângulos disjuntos, e a separação deve constar explicitamente em todos os manuscritos:

Frente	Pergunta
Parametrização (TCC paralelo)	Como o prior <i>entra</i> ? Geometria do gradiente da porta.
Regularização (submetido pelo grupo)	Quão fortemente o prior é <i>mantido</i> ? Coeficiente de penalização.
Este trabalho	O que a porta <i>contribui</i>? Atribuição frente a competidores.

As duas primeiras frentes são internas ao mecanismo; esta é externa e comparativa. Não compartilham braços experimentais nem resultados, e citam-se mutuamente.

10 Autoria

O aluno responde pela implementação, execução, análise e primeira redação, figurando como primeiro autor do manuscrito resultante. A orientação responde pela concepção, revisão metodológica e redação final.

Referências

- [1] Nørgaard, L., Saudland, A., Wagner, J., Nielsen, J. P., Munck, L., & Engelsen, S. B. (2000). Interval partial least-squares regression (iPLS): a comparative chemometric study with an example from near-infrared spectroscopy. *Applied Spectroscopy*, 54(3), 413–419.

- [2] Li, H., Liang, Y., Xu, Q., & Cao, D. (2009). Key wavelengths screening using competitive adaptive reweighted sampling method for multivariate calibration. *Analytica Chimica Acta*, 648(1), 77–84.
- [3] Leardi, R. (2000). Application of genetic algorithm-PLS for feature selection in spectral data sets. *Journal of Chemometrics*, 14(5–6), 643–655.
- [4] Mehmood, T., Liland, K. H., Snipen, L., & Sæbø, S. (2012). A review of variable selection methods in partial least squares regression. *Chemometrics and Intelligent Laboratory Systems*, 118, 62–69.
- [5] Chong, I.-G., & Jun, C.-H. (2005). Performance of some variable selection methods when multicollinearity is present. *Chemometrics and Intelligent Laboratory Systems*, 78(1–2), 103–112.
- [6] Lakens, D. (2017). Equivalence tests: a practical primer for *t*-tests, correlations, and meta-analyses. *Social Psychological and Personality Science*, 8(4), 355–362.
- [7] Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7, 1–30.
- [8] Wold, S., Sjöström, M., & Eriksson, L. (2001). PLS-regression: a basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, 58(2), 109–130.
- [9] Rinnan, Å., van den Berg, F., & Engelsen, S. B. (2009). Review of the most common pre-processing techniques for near-infrared spectra. *TrAC Trends in Analytical Chemistry*, 28(10), 1201–1222.
- [10] Kalivas, J. H. (1997). Two data sets of near infrared spectra. *Chemometrics and Intelligent Laboratory Systems*, 37(2), 255–259.
- [11] Coelho, C. J. *et al.* (2026). Prior-Guided Spectral Gating for Interpretable Deep Learning in Near-Infrared Spectroscopy. *Chemometrics and Intelligent Laboratory Systems*.